

# Weather-Aware Predictive Optimization of LEO Satellite Passes Using Calibrated Random Forests

Autor: Vignon Fidele Adanvo



# Introdução

## Contexto:

- As megaconstelações de satélites LEO (ex: Starlink, OneWeb) e 6ª geração de comunicações (6G) estão transformando o setor espacial.
- LEO oferece baixa latência e alta taxa de dados — ideal para IoT e comunicações globais.



## Problema:


- Apesar das vantagens, as comunicações LEO sofrem com **incertezas meteorológicas**, especialmente atenuação por chuva.
- Agendamentos tradicionais não consideram isso — resultando em falhas e uso ineficiente da rede.

## **Objetivo e Contribuições**

**Objetivo principal:**  
**Criar um sistema que integre previsão de atenuação de sinal no processo de agendamento, maximizando o throughput e a confiabilidade.**



# Metodologia



# Metodologia

- **Etapas principais:**
  - **Coleta de dados:**
    - Elementos orbitais (TLE) via *Celestrak* e dados meteorológicos via *Open-Meteo API*.

$$\text{label} = \begin{cases} 1 & \text{if maximum elevation} > 20^\circ \text{ and average precipitation} < 0.5 \text{ mm/h,} \\ 0 & \text{otherwise.} \end{cases}$$

- **Modelagem preditiva:**
  - Uso de **Random Forest (200 árvores)** para estimar a probabilidade de sucesso de cada passagem.
  - Calibração com *CalibratedClassifierCV* (5-fold CV).

# Metodologia

- **Otimização (MILP):**
  - A função objetivo maximiza o rendimento esperado ao mesmo tempo que penaliza o agendamento excessivo

$$\max \sum_i x_i \cdot p_i \cdot d_i \cdot R - C_{\text{setup}} \cdot \sum_i x_i,$$

$x_i \in \{0, 1\}$  uma variable de decisão binaria.  
 $p_i$  é a probabilidade prevista de sucesso.  
 $d_i$  é a duração da passagem do satellite  $i$ ,  
 $R$  é a taxa de bits de transmissão assumida  
 $C$  é o custo de penalidade associado ao tempo de configuração.


# Metodologia

- **Otimização (MILP):**
  - O algoritmo escolhe **quais passes de satélite** devem ser **agendados** para **maximizar a quantidade de dados transmitidos**, considerando:
    - a **duração** de cada passe,
    - a **probabilidade de sucesso da transmissão**.
- **Restrições:**
  - **Sem sobreposição de janelas:** dois passes que se sobrepõem (considerando tempo de preparação antes e depois) não podem ser escolhidos juntos.
  - **Capacidade total:** tempo máximo total permitido (opcional).
  - **Limite de número de passes:** quantidade máxima de passes agendados.

# Resultados

Table 2. Performance metrics of the classifier on the test set.

| Class        | Precision | Recall | F1-score    | Support |
|--------------|-----------|--------|-------------|---------|
| 0            | 0.95      | 0.97   | 0.96        | 38      |
| 1            | 0.98      | 0.95   | 0.96        | 42      |
| Accuracy     | —         | —      | <b>0.96</b> | 80      |
| Macro avg    | 0.96      | 0.96   | 0.96        | 80      |
| Weighted avg | 0.96      | 0.96   | 0.96        | 80      |





# Resultados

**Table 3. Scheduling Results: Expected and Realized Throughput**

| <b>Method</b>   | <b>Expected (kB)</b> | <b>Realized (kB)</b> |
|-----------------|----------------------|----------------------|
| Predictive MILP | 18,450               | 16,900               |
| Greedy Start    | 16,200               | 14,500               |
| Greedy Value    | 17,800               | 15,400               |
| SatNOGS         | 20,100               | 13,200               |

# Conclusões

O método integra aprendizado de máquina e MILP para melhorar o planejamento de passagens de satélites.

A abordagem é mais robusta e eficiente do que métodos heurísticos

O desempenho depende da qualidade das previsões meteorológicas e enfrenta limitações de escalabilidade.

# Próximos passos



Expandir o método para o agendamento coordenado de múltiplas estações terrestres.



Estender o framework para treinar modelos usando um ano completo de dados históricos, aumentando a robustez e a precisão das previsões.



Explorar otimização multiobjetivo considerando energia, equidade e prioridades de carga útil.



Incorporar aprendizado online (em que o modelo **é atualizado continuamente**) para ajustes em tempo real.



- O projeto completo está disponível no Overleaf:  
[https://www.overleaf.com/read/yfxpchskyscq#ab4\\_317](https://www.overleaf.com/read/yfxpchskyscq#ab4_317)  
Muito obrigado.

